TALLER DE PYTHON & IA APLICADA AL NEGOCIO · SECTOR BANCA

Automatización + IA Aplicada

Sesión 2

FACILITADOR

Marlon Leandro
Software Archiect | AI Engineer
MBA / Ing. Sistemas © 2026

FECHA

23 de abril de 2026

Agenda y Objetivos

Al finalizar esta sesión, el participante logrará:

- 🤖 Entender qué es un LLM y cómo puede integrarse con análisis de datos en banca.
- 📊 Usar IA para explicar datos, generar insights automáticos y crear resúmenes ejecutivos.
- 🏦 Aplicar Python + IA a casos reales: segmentación, riesgo y detección de patrones.
- ⚙️ Automatizar el reporting regulatorio con flujos reproducibles y auditables.
- 💻 Completar un caso integrador hands-on con dataset bancario real (clientes/créditos/TX).

¿Qué es un LLM y cómo ayuda al negocio?

LLM = Large Language Model

¿Qué es? Un modelo de IA entrenado con enormes cantidades de texto, capaz de entender y generar lenguaje natural.

Ejemplos: GPT (OpenAI), Claude (Anthropic), Gemini (Google). Accesibles vía API desde Python.

En banca: Analiza datos estructurados + texto no estructurado (reportes, correos, notas de crédito).

Costo: API de pago por uso. Procesamiento de miles de registros por pocos dólares.

Datos de entrada
Excel · CSV · Texto · Consulta

Modelo LLM (API)
GPT · Claude · Gemini

Procesamiento
Razonamiento · Análisis · Resumen

Output para el negocio
Reporte · Insight · Alerta · KPI

Uso de IA para Análisis de Datos

Explicar Datos

La IA lee tu DataFrame y genera en lenguaje natural una explicación de lo que muestran los datos: tendencias, anomalías y conclusiones clave.

Ejemplo de output:

"El segmento PYME muestra una mora del 12.4%, superior al límite del 8%. Se recomienda revisar los créditos > S/50,000."

Generar Insights

Convierte métricas crudas en recomendaciones accionables. La IA identifica patrones que tardarías horas en detectar manualmente.

Ejemplo de output:

"Las transacciones POS del segmento Retail aumentaron 23% los viernes. Oportunidad de campaña de cross-sell."

Resúmenes Automáticos

Genera reportes ejecutivos en segundos. Convierte tablas de datos en párrafos listos para enviar a gerencia o regulador.

Ejemplo de output:

"Resumen de cartera – Abril 2026: portafolio total S/4.2M, morosidad 6.1%, 3 segmentos en alerta temprana."

Python + LLM: Cómo se conectan

```python
import openai, pandas as pd

# 1. Cargar y analizar datos
df = pd.read_excel("cartera.xlsx")
resumen = df.groupby("segmento").agg(
    portafolio=("saldo","sum"),
    mora=("es_moroso","mean")
).reset_index()

# 2. Convertir a texto para el LLM
tabla_texto = resumen.to_string(index=False)

# 3. Llamar al LLM via API
client = openai.OpenAI(api_key="TU_KEY")
prompt = f"""
```

¿Qué necesitas?

Cuenta en OpenAI/Anthropic · API Key · pip install openai · Datos en DataFrame.

Costo estimado

GPT-4o: ~$0.01 por análisis completo. Para 500 reportes mensuales: < $5 USD.

Modelos disponibles

OpenAI GPT-4o · Anthropic Claude · Google Gemini · Llama 3 (open source, gratis).

Todos accesibles desde Python con una API similar.

Segmentación de Clientes con IA

1 — Datos
CRM + Core: ID, saldo, productos, transacciones, antigüedad

›

2 — Métricas
RFM: Recency, Frequency, Monetary. CLV y propensión

›

3 — IA analiza
LLM interpreta segmentos y genera perfiles en lenguaje natural

›

4 — Acción
Campañas personalizadas, alertas de churn, next-best-offer

Ejemplo de output IA - Perfiles de segmento:

Premium

Clientes con CLV alto, baja mora y alta frecuencia transaccional. Oferta: productos de inversión y beneficios exclusivos.

En riesgo

Reducción del 40% en transacciones últimos 90 días. Alta probabilidad de churn. Acción: llamada proactiva + oferta de retención.

Potencial

Saldo moderado y bajo endeudamiento. Receptivos a créditos de consumo. Campaña de cross-sell automatizada recomendada.

Detección de Patrones Sospechosos

Combinación de reglas Python + razonamiento LLM para fraude y anomalías:

Reglas Python (Pandas)

- Monto > umbral definido por segmento.
- Frecuencia inusual en ventana de 24h.
- Transacción fuera del horario habitual.
- Canal distinto al histórico del cliente.
- Geolocalización inconsistente (App vs POS).

IA / LLM interpreta

- "Esta secuencia de transacciones sugiere test de tarjeta clonada."
- "El patrón es consistente con fraude de cuenta nueva."
- "Riesgo ALTO: 3 señales concurrentes en 2 horas."
- "Recomiendo bloqueo preventivo y verificación biométrica."

Acción Automatizada

- Alerta en tiempo real al equipo de fraude.
- Bloqueo temporal automatizado de la cuenta.
- Notificación push al cliente para confirmar.
- Log auditable con evidencia para regulador.
- Reporte semanal de patrones nuevos detectados.

Análisis de Riesgo Simplificado con IA

Pipeline de scoring rápido:

1. 📋 **Datos del cliente**
   Saldo, mora histórica, productos activos, antigüedad.
2. 🔢 **Variables clave**
   DPD máx, ratio deuda/ingreso, frecuencia de pagos.
3. ⚖️ **Score Python**
   Reglas o modelo simple: semáforo Verde/Amarillo/Rojo.
4. 🤖 **Narrativa IA**
   LLM genera explicación del score para el gestor.
5. 📄 **Decisión**
   Output: recomendación + evidencia para expediente.

Output del sistema:

VERDE
720

Cliente: Ana Pérez · ID: 10421

Score: 720/1000 – Riesgo BAJO

Factores positivos: sin mora en 24 meses, ratio deuda/ingreso 28%, 3 productos activos.

Recomendación IA: APROBAR crédito hasta S/25,000 a 36 meses con tasa estándar.

Acción sugerida: verificar ingresos y proceder con firma digital.

Automatización de Reporting Regulatorio

De horas de trabajo manual a minutos con Python + IA:

Reportes Típicos

- SBS: cartera por segmento y tipo de crédito.
- NPL por categoría y zona geográfica.
- Ratio de cobertura de provisiones.
- Indicadores de liquidez diarios.

Flujo Automatizado

- Carga automática de fuentes (Core + CRM).
- Cálculo de KPIs con fórmulas auditables.
- Generación de tablas y gráficos en Excel.
- Narrativa ejecutiva generada por IA.

Beneficios Medibles

- 80% reducción de tiempo de elaboración.
- Cero errores de fórmula o copia manual.
- Versión única, trazable y reproducible.
- Auditoría completa del proceso.

El regulador recibe el mismo reporte, generado automáticamente, en minutos — no en días.

Caso Integrador Hands-On

Dataset tipo banca: 3 fuentes de datos integradas

clientes.xlsx

· cliente_id · nombre · segmento

· fecha_apertura · estado (Active/Inactive)

· edad · ingresos · zona_geografica

creditos.xlsx

· credito_id · cliente_id · tipo_credito

· saldo_actual · fecha_vencimiento

· dias_mora (DPD) · tasa_interes

transacciones.xlsx

· tx_id · cliente_id · monto

· canal (POS/App/Web/ATM)

· fecha_hora · comercio · tipo_tx

Objetivo: análisis completo de cartera y generación de insights ejecutivos con IA en una sesión.

Flujo Completo: 4 Pasos del Caso Integrador

1

Carga de Datos

pd.read_excel + merge de 3 fuentes

- › Importar clientes, créditos y TX.
- › Unir datasets por cliente_id.
- › Verificar shape, nulos y dtypes.

2

Limpieza Básica

Estandarizar y validar

- › Formatear fechas a datetime.
- › Corregir tipos (str → float).
- › Eliminar duplicados y outliers.

3

Análisis

KPIs y patrones con Pandas

- › Calcular mora por segmento.
- › Ticket promedio y volúmenes.
- › Top 10 clientes por riesgo.

4

Insights con IA

LLM genera narrativa ejecutiva

- › Enviar resumen al LLM via API.
- › Obtener alertas en lenguaje natural.
- › Exportar reporte Word/PDF.

Paso 1: Carga & Paso 2: Limpieza

```python
import pandas as pd

# PASO 1: CARGA DE DATOS
clientes = pd.read_excel("clientes.xlsx")
creditos = pd.read_excel("creditos.xlsx",
    parse_dates=["fecha_vencimiento"])
transacc = pd.read_excel("transacciones.xlsx",
    parse_dates=["fecha_hora"])

# Unir las 3 fuentes por cliente_id
base = clientes.merge(creditos,
    on="cliente_id", how="left")
print(f"Registros: {len(base)}")

# PASO 2: LIMPIEZA
```

Verificaciones clave

shape · dtypes · isnull().sum() · duplicated().sum()
Siempre validar antes de calcular KPIs.

Errores comunes

Fechas como texto (object). Montos con coma decimal. Códigos con espacios ocultos. Dobles registros por merge incorrecto.

Tip Google Colab

Subir los 3 archivos Excel directamente al entorno con:

```python
from google.colab import files
uploaded = files.upload()
```

O conectar Google Drive para persistencia.

Paso 3: Análisis y Cálculo de KPIs

```python
# PASO 3: ANÁLISIS Y KPIs
from datetime import date
ref = pd.Timestamp(date.today())

# Días de mora (DPD)
creditos["dpd"] = (
    ref - creditos["fecha_vencimiento"]
).dt.days.clip(lower=0)
creditos["es_moroso"] = creditos["dpd"] > 0

# KPIs por segmento
kpis = base.groupby("segmento").agg(
    portafolio  = ("saldo_actual", "sum"),
    clientes    = ("cliente_id",   "nunique"),
    mora_pct    = ("es_moroso",    "mean"),
```

KPIs calculados

Portafolio total · Mora % · DPD promedio · Ticket promedio · Clientes únicos · Alertas por segmento.

Semáforo de riesgo

- Verde: mora < 5%
- Amarillo: mora 5-8%
- Rojo: mora > 8%

Umbral configurable según política interna o normativa SBS.

Output esperado

DataFrame con KPIs listos para: exportar a Excel, visualizar, y enviar al LLM para narrativa ejecutiva.

Paso 4: Generación de Insights con IA

```python
# PASO 4: INSIGHTS CON IA
import openai
client = openai.OpenAI(api_key="TU_KEY")

tabla_kpis = kpis.to_string(index=False)
alertas = kpis[kpis["alerta"]][[
    "segmento", "mora_pct", "portafolio"
]].to_string(index=False)

prompt = f"""
Eres analista de riesgo bancario senior.
KPIs de cartera actuales:
{tabla_kpis}

Segmentos en alerta (mora > 8%):
```

Output del LLM (ejemplo):

RESUMEN EJECUTIVO – CARTERA ABRIL 2026

La cartera total asciende a S/4.2M con mora promedio de 6.8%. Se identifican 2 segmentos en alerta crítica.

ALERTAS CRÍTICAS:
› PYME: mora 12.4% (límite: 8%). Acción: revisión inmediata de créditos >S/30K.
› Microempresa: DPD promedio 45 días. Iniciar proceso de cobranza proactiva.

OPORTUNIDADES:
› Premium: baja mora y alto saldo. Potencial para productos de inversión (S/1.8M).
› Retail digital: +34% TX en App. Canal prioritario para campaña Q2.

PRÓXIMOS PASOS:
1. Reunión con riesgos – 24 hrs
2. Alertas automatizadas – esta semana
3. Campaña retención PYME – 7 días

Cierre y Siguientes Pasos

¡Has completado el taller completo de Python + IA Aplicada a Banca!

Lo que aprendiste

› Fundamentos Python: variables, loops, listas.

› Pandas: carga, limpieza, filtros y KPIs.

› LLMs: qué son y cómo conectarlos via API.

› Casos reales: segmentación, fraude, riesgo.

› Reporting automático con narrativa de IA.

Quick Wins para esta semana

› Automatiza un reporte que haces en Excel.

› Conecta tu análisis a GPT-4 o Claude.

› Genera tu primer resumen ejecutivo con IA.

› Comparte el script con tu equipo.

Tu hoja de ruta

› Semana 1-2: automatizar 1 reporte recurrente.

› Mes 1: scoring simple de cartera en Python.

› Mes 2: pipeline completo Python + IA.

› Mes 3: presentar resultados a gerencia.

El objetivo no es ser programadores — es tomar mejores decisiones de negocio usando tecnología.

¿Preguntas?

Marlon Leandro
Software Archiect | AI Engineer
MBA / Ing. Sistemas © 2026